

Московский государственный университет имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики

Обнаружение и локализация дефектов при селективном лазерном плавлении методами компьютерного зрения

Выпускная квалификационная работа

Выполнил: Буян Кирилл Игоревич

Научный руководитель: Синильщиков Илья Васильевич

Москва, 2026

Содержание

1	Введение	3
2	Основная часть	3
2.1	Библиотека Anomalib и подходы к задаче	3
2.2	Особенности датасета	4
2.3	FastFlow	5
2.4	SuperSimpleNet	8
3	Заключение	13
4	Источники	15

1 Введение

Задача обнаружения аномалий в изображениях состоит в том, чтобы определить, является ли объект нормальным или содержит дефект. В промышленной постановке этого часто недостаточно: кроме ответа на уровне всего изображения, полезно получить карту аномалий, то есть примерно показать область, из-за которой модель считает деталь дефектной. Поэтому в работе рассматриваются две связанные задачи: обнаружение дефектов и их локализация.

В классической сегментации для обучения нужны точные маски дефектов. В реальном производстве это неудобно: дефекты встречаются редко, их разметка требует эксперта, а сами дефекты могут сильно отличаться друг от друга. Поэтому многие современные методы используют обучение только на нормальных изображениях или слабую разметку, когда известна только метка изображения: нормальное оно или аномальное.

В данной работе эта постановка применяется к изображениям деталей, полученных на 3D-принтере методом селективного лазерного плавления. Для такого производства важно не пропустить дефект, так как он может указывать на нарушение процесса печати. При этом точных масок дефектов для основного датасета нет, поэтому основной упор сделан на методы, которые могут работать без пиксельной разметки или дообучаться по слабой разметке.

2 Основная часть

2.1 Библиотека Anomalib и подходы к задаче

Для экспериментов использовалась библиотека Anomalib. Она предоставляет готовые реализации моделей для обнаружения аномалий, инструменты для обучения, применения модели, подбора гиперпараметров и сравнения моделей [1]. В библиотеке есть как методы, основанные на признаках предобученных сетей, так и методы с генерацией синтетических аномалий, нормализующими потоками и другими подходами.

Основные группы методов можно кратко описать так:

- методы реконструкции обучаются восстанавливать нормальные изображения, а дефект ищется по ошибке восстановления;
- методы на признаках извлекают представления из предобученной нейронной сети и моделируют распределение нормальных объектов;
- дискриминативные методы учатся отличать нормальные и аномальные области, часто используя искусственно созданные аномалии;
- методы на нормализующих потоках оценивают правдоподобие признаков изображения и считают маловероятные области аномальными.

Для дальнейшего исследования были выбраны две модели: FastFlow и SuperSimpleNet. FastFlow интересен как быстрый метод на нормализующих потоках, показавший хорошие результаты на промышленных наборах данных. SuperSimpleNet интересен тем, что умеет использовать разные уровни разметки и хорошо подходит для ситуации, когда сначала доступны только нормальные данные, а позже появляются отдельные примеры дефектов.

2.2 Особенности датасета

Основной датасет состоит из изображений фрагментов деталей, полученных в процессе печати. Нормальные изображения были подготовлены с использованием масок объекта, но эти маски не являются масками дефектов. Они нужны только для выделения области детали и отбрасывания почти пустого фона. Для аномальных изображений доступны только сами примеры дефектов без точной пиксельной разметки.

Главная особенность датасета состоит в большой произвольности формы. В отличие от лабораторных наборов, здесь объект может занимать разную часть изображения, иметь разные границы и отличаться по общей геометрии. В качестве дефектов в первую очередь рассматриваются трещины и похожие локальные нарушения поверхности. Поэтому модель должна

не просто запомнить форму нормального объекта, а научиться выделять действительно подозрительные локальные области.

С точки зрения обучения это в основном постановка без учителя: для обучения доступны нормальные изображения, а точных масок аномалий нет. Если вручную собрать отдельные примеры дефектов и использовать только метку изображения, задача становится слабо размеченной. Для предварительной проверки методов также использовался MVТес AD, класс `metal_nut`. Он выбран как наиболее близкий по смыслу, поскольку содержит металлический объект и дефекты вроде царапин и деформаций. Однако отличие остается существенным: в MVТес AD объект имеет более стабильную форму и есть точные маски дефектов, а в датасете 3D-принтера форма намного менее фиксирована.

2.3 FastFlow

FastFlow решает задачу обнаружения и локализации аномалий через нормализующие потоки [2]. Сначала изображение проходит через предобученный экстрактор признаков, например ResNet или ViT. Затем признаки подаются в двумерный нормализующий поток, который учится переводить распределение признаков нормальных изображений в простое латентное распределение. Если при применении модели некоторый участок изображения плохо согласуется с распределением нормальных данных, его правдоподобие оказывается ниже, и он получает больший скор аномалии.

Общая схема метода показана на рисунке 1. Важная для нашей задачи деталь состоит в том, что FastFlow сохраняет пространственную структуру признаков, поэтому после оценки правдоподобия можно получить не только скор изображения, но и карту аномалий.

Важная особенность FastFlow в том, что модель естественно строит карту аномалий. В наших экспериментах скор всего изображения вычислялся по этой карте: брались верхние 0.1% пикселей с наибольшим значением аномальности и усреднялись:

$$S(x) = \frac{1}{k} \sum_{p \in \text{TopK}(A(x), k)} A_p(x), \quad k = \max(1, \lfloor 0.001HW \rfloor),$$




Рис. 1: Архитектура FastFlow.

где $A(x)$ - карта аномалий размера $H \times W$. Такой способ хорошо реагирует на небольшие локальные дефекты, но также становится чувствительным к ложным ярким областям на границах объекта или фоне.

FastFlow был выбран для проверки по двум причинам. Во-первых, он хорошо показывает себя на бенчмарках промышленного контроля качества. Во-вторых, он достаточно быстрый и имеет понятную процедуру обучения только на нормальных изображениях. Контрольные запуски на MVTec AD для класса `metal_nut` подтвердили, что реализация воспроизводит ожидаемое поведение: пиксельный ROC-AUC в тестовых прогонах был около 0.98, а ROC-AUC по изображениям доходил до 1.0.

После этого модель была проверена на датасете 3D-принтера. Основные результаты приведены в таблице 1. Метрика ROC-AUC по изображениям использовалась как основная для обнаружения, так как масок дефектов в этом датасете нет.

Отдельно важен третий запуск с ResNet18. В нем валидационная ошибка FastFlow уменьшилась до -179942.76 , то есть формально оптимизация шла успешно. Однако ROC-AUC по изображениям снизился до 0.633. На рисунке 2, видно, что функция потерь продолжала уменьшаться, но это не привело к улучшению тестовой метрики. Это показывает, что для данной задачи значение функции потерь FastFlow нельзя использовать как единственный критерий выбора лучшей модели.

Также проверялась замена ResNet18 на трансформерный экстрактор





Рис. 2: Функция потерь FastFlow при увеличенном числе эпох: ошибка уменьшается, но качество обнаружения на тесте падает.

Запуск	Тест	ROC-AUC	Комментарий
ResNet18, базовый запуск, 8 эпох	37 норм., 46 аном.	0.829	Базовый уровень качества.
ResNet18, расширенные аугментации, 8 эпох	37 норм., 46 аном.	0.838	Небольшой прирост, но точность при пороге 0.5 осталась 0.554.
ResNet18, расширенные аугментации, 14 эпох	37 норм., 46 аном.	0.633	Ошибка обучения продолжала уменьшаться, но качество на тесте стало хуже.
Трансформерный экстрактор признаков, 8 шагов потока	36 норм., 46 аном.	0.698	Увеличение размера изображения до 384 и более сложный экстрактор признаков не дали улучшения.
Трансформерный экстрактор признаков, 12 шагов потока	36 норм., 46 аном.	0.523	Механическое изменение числа шагов потока привело к падению качества.

Таблица 1: Результаты FastFlow на датасете 3D-принтера.

признаков `deit_base_distilled_patch16_384`. Для него размер входного изображения пришлось увеличить с 256 до 384, при этом схема разделения данных на обучение, валидацию и тест оставалась той же. Улучшения качества не наблюдалось. Кроме того, стало заметно, что параметр `flow_steps` требует отдельного подбора: изменение числа шагов потока заметно влияло на итоговую метрику.

В целом FastFlow оказался не самым удобным решением для рассматриваемого датасета. Модель чувствительна к настройкам, а функция потерь не всегда отражает качество обнаружения. Более важная проблема связана с произвольной формой деталей: модель часто реагирует на форму объекта, границы или неидеально черный фон. Так как итоговый скор изображения берется из карты аномалий, такие ложные области ухудшают метрику обнаружения.

2.4 SuperSimpleNet

SuperSimpleNet использует другую идею [3, 4]. Сначала изображение пропускается через предобученный экстрактор признаков. Затем призна-

ки приводятся к удобному пространственному размеру, проходят через небольшой адаптер, и на этапе обучения в них добавляются синтетические аномалии. Для генерации таких аномалий используется маска на основе шума Перлина: она дает связные области, которые больше похожи на реальные дефекты, чем независимый шум по пикселям.

Схема архитектуры SuperSimpleNet приведена на рисунке 3. В ней отдельно выделены генерация синтетических аномалий, сегментационная ветвь и классификационная ветвь.




Рис. 3: Архитектура SuperSimpleNet.

Архитектура содержит две ветви: сегментационную, которая предсказывает карту аномалий, и классификационную, которая выдает скор всего изображению. Это важно, потому что хорошая карта аномалий и хорошее решение на уровне изображения не всегда совпадают. Например, карта может содержать небольшие ложные области, а классификационная голова может научиться принимать более устойчивое решение.

Еще одно преимущество SuperSimpleNet состоит в гибкости по разметке. В полностью неразмеченном режиме модель обучается на нормальных изображениях и синтетических аномалиях. Если появляются реальные аномальные изображения без масок, можно дообучать классификационную

голову по меткам изображений. Если доступны точные маски, можно до-обучать и сегментационную часть.

Сначала SuperSimpleNet был проверен на MVTec AD, класс `metal_nut`. Контрольный запуск дал высокий результат: $pixel\ AUPRO = 0.9121$ и $image\ ROC-AUC = 0.9945$. Это подтвердило, что метод корректно работает на стандартной задаче с доступными масками и может быть перенесен на основной датасет.

Проверка синтетической валидации

Так как для датасета 3D-принтера нет масок дефектов, была проверена гипотеза: можно ли оценивать локализацию на синтетическом датасете, построенном из валидационных нормальных изображений. Идея оказалась ненадежной. В первом запуске синтетические метрики были низкими: $synthetic\ pixel\ AUPRO = 0.161$ и $synthetic\ image\ ROC-AUC = 0.490$, при этом ROC-AUC по реальным тестовым изображениям был 0.895. Во втором запуске синтетические метрики стали почти идеальными: 0.9996 и 0.9998, но реальный ROC-AUC по изображениям почти не изменился и составил 0.892.

Из этого следует, что синтетические метрики можно использовать как диагностический сигнал, но нельзя считать их надежной заменой реальной тестовой оценки.

Сравнение с FastFlow

Тестовый набор для SuperSimpleNet использовался тот же, что и для FastFlow с ResNet18: 37 нормальных изображений и 46 аномальных. Уже без специального подбора SuperSimpleNet показал ROC-AUC по изображениям около 0.89-0.90, то есть выше базовых запусков FastFlow. При визуальной проверке карт аномалий также было заметно, что SuperSimpleNet меньше реагирует на общую форму объекта и неидеальный фон. Примеры таких карт приведены на рисунке 4.

Важно, что это сравнение не связано только с числом эпох. Для FastFlow отдельно проверялось увеличение числа эпох: ошибка продолжала умень-




Рис. 4: Сравнение карт аномалий ResNet-18 и SuperSimpleNet на примерах из датасета 3D-принтера.

шаться, но качество обнаружения не росло, а падало. Поэтому в данной задаче дополнительное обучение FastFlow само по себе не решало проблему.

Дообучение при наличии слабой разметки

На MVТес AD была дополнительно проверена идея дообучать не только классификационную голову, но и сегментационную ветвь в слабо размеченном режиме, когда известны только метки изображений. Для этого использовалась следующая функция ошибки. Пусть $y_i \in \{0, 1\}$ - метка изображения, s_i - логит классификационной головы, M_i - логиты карты аномалий, а

$$m_i = \text{meanTopK}(M_i, r), \quad r = 0.01.$$

Тогда

$$L = L_s + 0.5L_m + 0.05L_n,$$

где

$$L_s = \text{BCE}(s_i, y_i), \quad L_m = \text{BCE}(m_i, y_i).$$

Последний член L_n подавляет карту аномалий на нормальных изображениях и считается как бинарная кросс-энтропия между M_i и нулевой маской только для объектов с $y_i = 0$.

Однако эксперименты на `metal_nut` показали, что такое дообучение сегментационной ветви по слабой разметке не улучшило локализацию. В первом запуске *pixel AUPRO* изменился с 0.9283 до 0.9280, во втором снизился с 0.9283 до 0.9165. При этом дообучение с настоящими масками улучшало сегментацию: *pixel AUPRO* вырос до 0.9338 в первом запуске и до 0.9362 во втором. Поэтому для основного датасета 3D-принтера, где масок дефектов нет, было выбрано дообучение только классификационной головы.

Результат дообучения на датасете 3D-принтера приведен в таблице 2. Дообучение использовало только метки изображений и не требовало масок дефектов.

После дообучения ROC-AUC по изображениям вырос с 0.900 до 0.980, а

Состояние модели	ROC-AUC	Точность при пороге 0.5	d Коэна
До дообучения головы	0.900	0.554	1.717
После дообучения головы	0.980	0.928	2.936

Таблица 2: Дообучение классификационной головы SuperSimpleNet на датасете 3D-принтера.

точность при пороге 0.5 выросла с 0.554 до 0.928. Для основной прикладной задачи это существенный результат, потому что главная цель - надежно обнаружить дефектную деталь. Локализация при этом остается доступной через карту аномалий, хотя без масок дефектов ее можно оценивать только визуально.

Итог по SuperSimpleNet следующий: модель лучше подходит для деталей произвольной формы, чем FastFlow, и ее можно полезно дообучать даже без масок аномалий. Это особенно важно для производственной задачи, где собрать маски дефектов трудно, а отдельные примеры аномальных изображений получить значительно проще.

3 Заключение

В работе были рассмотрены методы компьютерного зрения для обнаружения и локализации дефектов при селективном лазерном плавлении. Основная сложность задачи связана с тем, что для производственного датасета нет точных масок дефектов, а форма деталей сильно меняется от изображения к изображению.

Для экспериментов были выбраны FastFlow и SuperSimpleNet. FastFlow был протестирован как быстрый метод на нормализующих потоках, который хорошо работает на стандартных промышленных бенчмарках. На датасете 3D-принтера он показал приемлемый базовый результат, но оказался чувствительным к настройкам, числу шагов потока и ложным срабатываниям на форму объекта. Также было показано, что уменьшение функции потерь FastFlow не гарантирует роста качества обнаружения.

SuperSimpleNet показал себя лучше в данной постановке. Уже базовая модель превзошла FastFlow по ROC-AUC на тестовом наборе, а дообуче-

ние классификационной головы по слабой разметке повысило ROC-AUC до 0.980 и точность при пороге 0.5 до 0.928. При этом модель сохраняет карту аномалий, что дает возможность локализовать подозрительную область.

Итоговый результат можно считать хорошим для обнаружения дефектов и неплохим для локализации. Для данной производственной задачи это разумный приоритет: сначала важно надежно определить, что деталь дефектная, а локализация нужна как дополнительное объяснение и помощь инженеру при анализе причины дефекта.

4 Источники

Список литературы

- [1] Anomalib Documentation. *Anomalib in 15 Minutes*. https://anomalib.readthedocs.io/en/v2.0.0/markdown/get_started/anomalib.html
- [2] Yu J., Zheng Y., Wang X., Li W., Wu Y., Zhao R., Wu L. *FastFlow: Unsupervised Anomaly Detection and Localization via 2D Normalizing Flows*. <https://arxiv.org/pdf/2111.07677>
- [3] Rolih B., Fučka M., Skočaj D. *SuperSimpleNet: Unifying Unsupervised and Supervised Learning for Fast and Reliable Surface Defect Detection*. <https://arxiv.org/pdf/2408.03143>
- [4] Rolih B., Fučka M., Skočaj D. *No label left behind: a unified surface defect detection model for all supervision regimes*. <https://link.springer.com/article/10.1007/s10845-025-02680-8>